

Análisis de E-Commerce con SQL

Silvia Katerin Angel Camargo

Agosto de 2023

Competencias y Enfoques Aplicados

GOOGLE BIGQUERY | SQL | ADVANCED QUERIES | DATA MODELING | ERD

Parte 1. Esquema y Exploración Inicial

```
-- 1.1 ¿qué columnas y tipos de datos tiene cada tabla?

SELECT table_name, column_name, data_type
FROM `brazilian-e-commerce-511503.ecommerce_data.INFORMATION_SCHEMA.COLUMNS`
ORDER BY table_name, ordinal_position;
```

Fila	table_name	column_name	data_type
1	olist_customers_dataset	customer_id	STRING
2	olist_customers_dataset	customer_unique_id	STRING
3	olist_customers_dataset	customer_zip_code_prefix	INT64
4	olist_customers_dataset	customer_city	STRING
5	olist_customers_dataset	customer_state	STRING
6	olist_order_items_dataset	order_id	STRING
7	olist_order_items_dataset	order_item_id	INT64
8	olist_order_items_dataset	product_id	STRING
9	olist_order_items_dataset	seller_id	STRING
10	olist_order_items_dataset	shipping_limit_date	TIMESTAMP
11	olist_order_items_dataset	price	FLOAT64
12	olist_order_items_dataset	freight_value	FLOAT64
13	olist_order_payments_dataset	order_id	STRING
14	olist_order_payments_dataset	payment_sequential	INT64
15	olist_order_payments_dataset	payment_type	STRING
16	olist_order_payments_dataset	payment_installments	INT64
17	olist_order_payments_dataset	payment_value	FLOAT64
18	olist_orders_dataset	order_id	STRING
19	olist_orders_dataset	customer_id	STRING
20	olist_orders_dataset	order_status	STRING
21	olist_orders_dataset	order_purchase_timestamp	TIMESTAMP
22	olist_orders_dataset	order_approved_at	TIMESTAMP
23	olist_orders_dataset	order_delivered_carrier_date	TIMESTAMP
24	olist_orders_dataset	order_delivered_customer_date	TIMESTAMP
25	olist_orders_dataset	order_estimated_delivery_date	TIMESTAMP
26	olist_products_dataset	product_id	STRING
27	olist_products_dataset	product_category_name	STRING
28	olist_products_dataset	product_name_lenght	INT64
29	olist_products_dataset	product_description_lenght	INT64
30	olist_products_dataset	product_photos_qty	INT64
31	olist_products_dataset	product_weight_g	INT64
32	olist_products_dataset	product_length_cm	INT64
33	olist_products_dataset	product_height_cm	INT64
34	olist_products_dataset	product_width_cm	INT64

Interpretación: El dataset de Olist contiene cinco tablas relacionadas, con 34 columnas en total. El modelo permite analizar ventas, fletes, pagos, tiempos de entrega y el peso de los productos, es decir, los cuatro frentes planteados en los objetivos.

Limitaciones:

- No hay datos de stock, por lo que no se puede analizar inventario, solo catálogo y peso.

- Las categorías están en portugués y no hay tabla de traducción.

```
-- 1.2 ¿cuántos pedidos y cuántos clientes reales hay?

SELECT
  COUNT(*) AS filas,
  COUNT(DISTINCT customer_id) AS customer_id_distintos,
  COUNT(DISTINCT customer_unique_id) AS clientes_unicos
FROM `brazilian-e-commerce-511503.ecommerce_data.olist_customers_dataset`;
```

Fila	filas	customer_id_distintos	clientes_unicos
1	99441	99441	96096

Interpretación: `customer_id` se genera por pedido, por eso coincide con el número de órdenes. La persona real es `customer_unique_id` (96.096). Unos 3.345 pedidos (≈3,4%) son de clientes recurrentes, lo que indica una recompra baja.

```
-- 1.3 ¿qué periodo cubren los pedidos y cuántos llegaron a estado 'delivered'?

SELECT
  COUNT(*) AS total_ordenes,
  COUNTIF(order_status = 'delivered') AS ordenes_entregadas,
  MIN(DATE(order_purchase_timestamp)) AS primer_pedido,
  MAX(DATE(order_purchase_timestamp)) AS ultimo_pedido
FROM `brazilian-e-commerce-511503.ecommerce_data.olist_orders_dataset`;
```

Fila	total_ordene	ordenes_entregadas	primer_pedido	ultimo_pedido
1	99441	96478	4/09/2016	17/10/2018

Interpretación: El dataset abarca poco más de dos años. Un 97,0% de los pedidos llegó a su destino, lo que respalda la fiabilidad de las métricas logísticas.

```
-- 1.4 ¿cómo se distribuye el volumen en el tiempo y qué meses tienen datos
completos?

SELECT
  FORMAT_DATE('%Y-%m', DATE(order_purchase_timestamp)) AS anio_mes,
  COUNT(*) AS total_ordenes
FROM `brazilian-e-commerce-511503.ecommerce_data.olist_orders_dataset`
GROUP BY anio_mes
ORDER BY anio_mes;
```

Fila	anio_mes	total_ordenes
1	2016-09	4
2	2016-10	324
3	2016-12	1
4	2017-01	800
5	2017-02	1780
6	2017-03	2682
7	2017-04	2404
8	2017-05	3700
9	2017-06	3245
10	2017-07	4026
11	2017-08	4331
12	2017-09	4285
13	2017-10	4631
14	2017-11	7544
15	2017-12	5673
16	2018-01	7269
17	2018-02	6728
18	2018-03	7211
19	2018-04	6939
20	2018-05	6873
21	2018-06	6167
22	2018-07	6292
23	2018-08	6512
24	2018-09	16
25	2018-10	4
Total		**99441**

Interpretación: El 99,6% de los pedidos se concentra entre enero de 2017 y agosto de 2018. Los datos de 2016 y de septiembre-octubre de 2018 son demasiado escasos para sacar conclusiones, por lo que el crecimiento interanual comparara enero-agosto de 2017 con enero-agosto de 2018, para evitar comparar un año completo con uno parcial.

```
-- 1.5 ¿en cuántos estados y ciudades hay clientes?
-- Supuesto: se cuenta la pareja ciudad-estado porque hay ciudades con el mismo
nombre en estados distintos.

SELECT
  COUNT(DISTINCT customer_state) AS total_estados,
  COUNT(DISTINCT CONCAT(customer_city, '-', customer_state)) AS total_ciudades
FROM `brazilian-e-commerce-511503.ecommerce_data.olist_customers_dataset`;
```

Fila	total_estados	total_ciudades
1	27	4310

Interpretación: Hay clientes en todos los estados de Brasil y en 4.310 ciudades.

Conclusiones de la Parte 1

1. El análisis se basa en 99.441 pedidos de 96.096 clientes, con una ventana efectiva de 20 meses.

2. La recompra es baja (≈3,4%).

3. Hay presencia en los 27 estados, pero la distribución no es uniforme (Parte 3).

Parte 2: Tendencias y Estacionalidad

```
-- 2.1 ¿Cómo evolucionó el número de pedidos a lo largo de los años, comparando
periodos equivalentes?
-- Supuesto:  Se busca comparar enero-agosto de 2017 con enero-agosto de 2018
(únicos periodos completos)

SELECT
  EXTRACT(YEAR FROM order_purchase_timestamp) AS anio,
  COUNT(order_id) AS total_pedidos,
  COUNTIF(EXTRACT(MONTH FROM order_purchase_timestamp) BETWEEN 1 AND 8) AS
pedidos_ene_ago,
  COUNT(DISTINCT EXTRACT(MONTH FROM order_purchase_timestamp)) AS
meses_con_pedidos
FROM `brazilian-e-commerce-511503.ecommerce_data.olist_orders_dataset`
GROUP BY anio
ORDER BY anio;
```

Fila	anio	total_pedidos	pedidos_ene_ago	meses_con_pedidos
1	2016	329	0	3
2	2017	45101	22968	12
3	2018	54011	53991	10

Interpretación: Los pedidos de enero a agosto pasaron de 22.968 en 2017 a 53.991 en 2018, un crecimiento de **+135,07%**. Se compara solo ese periodo porque es el único completo en ambos años.

```
-- 2.2 ¿Cómo varía el número de pedidos mes a mes, comparando 2017 y 2018 por
separado?
-- Supuesto: no se suman meses de años distintos; 2016 y sep-oct 2018 se excluyen
por tener datos casi nulos.

SELECT
```

```
  EXTRACT(MONTH FROM order_purchase_timestamp) AS mes_num,
  COUNTIF(EXTRACT(YEAR FROM order_purchase_timestamp) = 2017) AS pedidos_2017,
  COUNTIF(EXTRACT(YEAR FROM order_purchase_timestamp) = 2018) AS pedidos_2018
FROM `brazilian-e-commerce-511503.ecommerce_data.olist_orders_dataset`
WHERE DATE(order_purchase_timestamp) BETWEEN '2017-01-01' AND '2018-08-31'
GROUP BY mes_num
ORDER BY mes_num;
```

Fila	mes_num	pedidos_2017	pedidos_2018
1	1	800	7269
2	2	1780	6728
3	3	2682	7211
4	4	2404	6939
5	5	3700	6873
6	6	3245	6167
7	7	4026	6292
8	8	4331	6512
9	9	4285	0
10	10	4631	0
11	11	7544	0
12	12	5673	0

Interpretación: En 2017 los pedidos crecen de forma sostenida, de 800 en enero a 4.631 en octubre, con dos leves retrocesos en abril y junio. En noviembre se produce un salto a **7.544 pedidos (+63% frente a octubre)**, el máximo de todo el dataset, que coincide con el Black Friday (24/11/2017). En diciembre baja a 5.673 (-25%). En 2018 los pedidos se estabilizan en una meseta de entre 6.167 y 7.269 al mes. Frente a 2017, el volumen pasa de ser 9,1 veces mayor en enero a 1,5 veces mayor en agosto, es decir, el crecimiento interanual se desacelera a lo largo del año.

```
-- 2.3 ¿A qué horas exactas se realizan más pedidos?

SELECT
  EXTRACT(HOUR FROM order_purchase_timestamp) AS hora,
  COUNT(*) AS total_pedidos
FROM `brazilian-e-commerce-511503.ecommerce_data.olist_orders_dataset`
GROUP BY hora
ORDER BY hora;
```

Fila	hora	total_pedidos
1	0	2394
2	1	1170
3	2	510
4	3	272
5	4	206
6	5	188
7	6	502
8	7	1231
9	8	2967
10	9	4785
11	10	6177
12	11	6578
13	12	5995
14	13	6518
15	14	6569
16	15	6454
17	16	6675
18	17	6150
19	18	5769
20	19	5982
21	20	6193
22	21	6217
23	22	5816
24	23	4123

Interpretación: de 10:00 a 22:59 se realiza el 81,5% de los pedidos, con entre 5.769 y 6.675 pedidos por hora. La hora con más pedidos es las 16:00 (6.675), seguida de las 11:00 (6.578) y las 14:00 (6.569). Hay un descenso hacia las 18:00 (5.769) y un repunte nocturno a las 20:00 y 21:00 (6.193 y 6.217). Después de las 22:00 la actividad cae con fuerza (4.123 a las 23:00) y llega a su mínimo a las 05:00, con solo 188 pedidos. Entre las 02:00 y las 06:00 hay menos de 520 pedidos por hora

Limitaciones:

- Se asume que las horas del dataset están en hora local de Brasil. Brasil tiene varias zonas horarias, y no es posible confirmarlo desde los datos.

Parte 3: Distribución de Clientes por Estado

```
-- 3.1 ¿Cómo se distribuyen los clientes entre todos los estados?
-- Supuesto: cliente = customer_unique_id (customer_id se genera por pedido).
```

```
WITH clientes_estado AS (
  SELECT
    customer_state AS estado_cliente,
    COUNT(DISTINCT customer_unique_id) AS total_clientes_unicos
  FROM `brazilian-e-commerce-511503.ecommerce_data.olist_customers_dataset`
  GROUP BY customer_state
)
SELECT
  estado_cliente,
  total_clientes_unicos,
  ROUND(100 * total_clientes_unicos / SUM(total_clientes_unicos) OVER (), 1) AS
pct_clientes
FROM clientes_estado
ORDER BY total_clientes_unicos DESC, estado_cliente;
```

Fila	estado_cliente	total_clientes_unicos	pct_clientes
1	SP	40302	41.9
2	RJ	12384	12.9
3	MG	11259	11.7
4	RS	5277	5.5
5	PR	4882	5.1
6	SC	3534	3.7
7	BA	3277	3.4
8	DF	2075	2.2
9	ES	1964	2.0
10	GO	1952	2.0
11	PE	1609	1.7
12	CE	1313	1.4
13	PA	949	1.0
14	MT	876	0.9
15	MA	726	0.8
16	MS	694	0.7
17	PB	519	0.5
18	PI	482	0.5
19	RN	474	0.5
20	AL	401	0.4
21	SE	342	0.4
22	TO	273	0.3
23	RO	240	0.2
24	AM	143	0.1
25	AC	77	0.1
26	AP	67	0.1
27	RR	45	0.0

Interpretación: Los clientes se concentran en el Sureste. São Paulo reúne el 41,9% de los clientes únicos (40.302), más de tres veces los de Río de Janeiro (12.384; 12,9%) y Minas Gerais (11.259; 11,7%). Entre los tres suman el **66,5%**, es decir, dos tercios de la base, y con Rio Grande do Sul y Paraná llegan al 77,1%. En el otro

extremo, los 14 estados de Mato Grosso a Roraima aportan cada uno menos del 1% de los clientes

Limitaciones:

- La suma de clientes por estado (96.136) supera en 40 a los clientes únicos (96.096), lo que se puede pensar que es porque unos pocos clientes figuran en dos estados. La diferencia es del 0,04% y no afecta las conclusiones.

Parte 4: Rendimiento de Entrega

```
-- 4.1 ¿Qué estados tienen el tiempo promedio de entrega más alto y más bajo?
-- Supuestos: tiempo de entrega = días entre la compra y la entrega al cliente;
solo pedidos con fecha de entrega.
```

```
WITH tiempos_entrega AS (
  SELECT
    o.order_id,
    c.customer_state,
    DATE_DIFF(order_delivered_customer_date, order_purchase_timestamp, DAY) AS
dias_entrega
  FROM `brazilian-e-commerce-511503.ecommerce_data.olist_orders_dataset` o
  JOIN `brazilian-e-commerce-511503.ecommerce_data.olist_customers_dataset` c
USING (customer_id)
  WHERE order_delivered_customer_date IS NOT NULL
),
ranking_tiempos AS (
  SELECT
    customer_state,
    COUNT(*) AS total_pedidos,
    ROUND(AVG(dias_entrega), 2) AS tiempo_promedio_entrega,
    DENSE_RANK() OVER (ORDER BY AVG(dias_entrega) DESC) AS rank_lentos,
    DENSE_RANK() OVER (ORDER BY AVG(dias_entrega)) AS rank_rapidos
  FROM tiempos_entrega
  GROUP BY customer_state
)
SELECT
  customer_state AS estado_cliente,
  total_pedidos,
  tiempo_promedio_entrega,
  CASE
    WHEN rank_lentos <= 5 THEN 'Top 5 Más Lentos'
    WHEN rank_rapidos <= 5 THEN 'Top 5 Más Rápidos'
  END AS categoria_rank
FROM ranking_tiempos
WHERE rank_lentos <= 5 OR rank_rapidos <= 5
ORDER BY tiempo_promedio_entrega DESC;
```

Fila	estado_cliente	total_pedidos	tiempo_promedio_entrega	categoria_rank
1	RR	41	28.98	Top 5 Más Lentos
2	AP	67	26.73	Top 5 Más Lentos
3	AM	145	25.99	Top 5 Más Lentos
4	AL	397	24.04	Top 5 Más Lentos
5	PA	946	23.32	Top 5 Más Lentos
6	SC	3547	14.48	Top 5 Más Rápidos
7	DF	2080	12.51	Top 5 Más Rápidos
8	MG	11355	11.54	Top 5 Más Rápidos
9	PR	4923	11.53	Top 5 Más Rápidos
10	SP	40495	8.3	Top 5 Más Rápidos

Interpretación: Los cinco estados más lentos son del Norte y Nordeste (entre 23,32 y 28,98 días) y los cinco más rápidos son del Sureste, el Sur y el Distrito Federal (entre 8,30 y 14,48 días). Roraima tarda 3,5 veces más que São Paulo (28,98 frente a 8,30 días).

Limitaciones:

- El tiempo incluye la preparación del vendedor y el transporte, y el dataset no permite separarlos.

Parte 5: Métodos de Pago y Análisis de Cuotas

```
-- 5.1 ¿Qué métodos de pago usan los clientes y con qué frecuencia?
-- Supuesto: un pedido puede usar más de un método de pago.

SELECT
  payment_type AS tipo_pago,
  COUNT(DISTINCT order_id) AS total_pedidos,
  ROUND(100 * COUNT(DISTINCT order_id) /
    (SELECT COUNT(DISTINCT order_id)
     FROM `brazilian-e-commerce-
511503.ecommerce_data.olist_order_payments_dataset`), 1) AS pct_pedidos
FROM `brazilian-e-commerce-511503.ecommerce_data.olist_order_payments_dataset`
GROUP BY payment_type
ORDER BY total_pedidos DESC;
```

Fila	tipo_pago	total_pedidos	pct_pedidos
1	credit_card	76505	76.9
2	boleto	19784	19.9
3	voucher	3866	3.9
4	debit_card	1528	1.5
5	not_defined	3	0.0

Interpretación: La tarjeta de crédito es el método dominante: se usa en el 76,9% de los pedidos. Junto con el boleto (19,9%) cubren casi el 97% de los pedidos, y el voucher (3,9%) y la tarjeta de débito (1,5%) son marginales.

- Un pedido puede usar más de un método, por eso los porcentajes suman 102,2%.

```
-- 5.2 ¿Cómo se distribuyen los pagos con tarjeta de crédito según el número de
cuotas?
-- Supuesto: se cuentan pagos (un pedido puede tener más de uno); solo tarjeta de
crédito.

SELECT
  CASE
    WHEN payment_installments <= 1 THEN '1. Una cuota (pago único)'
    WHEN payment_installments <= 3 THEN '2. 2 a 3 cuotas'
    WHEN payment_installments <= 6 THEN '3. 4 a 6 cuotas'
    WHEN payment_installments <= 10 THEN '4. 7 a 10 cuotas'
    ELSE '5. Más de 10 cuotas'
  END AS rango_cuotas,
  COUNT(*) AS total_pagos,
  ROUND(100 * COUNT(*) / SUM(COUNT(*)) OVER (), 1) AS pct_pagos,
  ROUND(AVG(payment_value), 2) AS valor_promedio_pago
FROM `brazilian-e-commerce-511503.ecommerce_data.olist_order_payments_dataset`
WHERE payment_type = 'credit_card'
GROUP BY rango_cuotas
ORDER BY rango_cuotas;
```

Fila	rango_cuotas	total_pagos	pct_pagos	valor_promedio_pago
1	1. Una cuota (pa	25457	33.1	95.87
2	2. 2 a 3 cuotas	22874	29.8	134.23
3	3. 4 a 6 cuotas	16257	21.2	181.32
4	4. 7 a 10 cuotas	11866	15.5	333.83
5	5. Más de 10 cuo	341	0.4	358.34

Interpretación: Dos de cada tres pagos con tarjeta (66,9%) se hacen en 2 o más cuotas, y solo el 33,1% es pago único. El valor promedio crece con las cuotas: de 95,87 BRL en pago único a 333,83 BRL en 7 a 10 cuotas, unas 3,5 veces más.

- Lla relación entre cuotas y valor es una asociación, no prueba que financiar aumente la compra.

Parte 6: Catálogo de Productos e Impacto Logístico

```
-- 7.1 ¿Qué categorías de producto generan más ingresos y cuánto pesa cada una?
-- Supuestos: ingresos = suma de price (productos, sin flete); se incluyen todos
los estados de pedido;
--            las categorías se muestran con su nombre original (en portugués).

SELECT
  COALESCE(p.product_category_name, 'Desconocido') AS categoria_producto,
  COUNT(*) AS total_articulos_vendidos,
  ROUND(SUM(i.price), 2) AS ingresos_totales,
```

```
  ROUND(100 * SUM(i.price) / SUM(SUM(i.price)) OVER (), 1) AS pct_ingresos,
  ROUND(AVG(i.price), 2) AS precio_promedio_articulo
FROM `brazilian-e-commerce-511503.ecommerce_data.olist_order_items_dataset` i
JOIN `brazilian-e-commerce-511503.ecommerce_data.olist_products_dataset` p
  ON i.product_id = p.product_id
GROUP BY categoria_producto
ORDER BY ingresos_totales DESC
LIMIT 15;
```

Fila	categoria_producto	total_articulos_vendidos	ingresos_totales	pct_ingresos	precio_promedio_articulo
1	beleza_saude	9670	1258681.34	9.3	130.16
2	relogios_presentes	5991	1205005.68	8.9	201.14
3	cama_mesa_banho	11115	1036988.68	7.6	93.3
4	esporte_lazer	8641	988048.97	7.3	114.34
5	informatica_acessorios	7827	911954.32	6.7	116.51
6	moveis_decoracao	8334	729762.49	5.4	87.56
7	cool_stuff	3796	635290.85	4.7	167.36
8	utilidades_domesticas	6964	632248.66	4.7	90.79
9	automotivo	4235	592720.11	4.4	139.96
10	ferramentas_jardim	4347	485256.46	3.6	111.63
11	brinquedos	4117	483946.6	3.6	117.55
12	bebes	3065	411764.89	3.0	134.34
13	perfumaria	3419	399124.87	2.9	116.74
14	telefonia	4545	323667.53	2.4	71.21
15	moveis_escritorio	1691	273960.7	2.0	162.01

Interpretación: Los ingresos están repartidos entre varias categorías, sin que una domine. La mayor, Belleza y salud, aporta el 9,3% de los ingresos por productos (1,26 millones de BRL), y las cinco primeras suman casi el 40%. Las 15 categorías de la tabla reúnen cerca del 76% del total. Volumen e ingresos no coinciden: Cama, mesa y baño es la categoría con más artículos vendidos (11.115), pero queda tercera en ingresos por su precio bajo (93,30 BRL en promedio). En cambio, Relojes y regalos vende casi la mitad de artículos (5.991) y es segunda en ingresos (8,9%), gracias al precio promedio más alto de la tabla (201,14 BRL). En el extremo opuesto, Telefonía vende 4.545 artículos pero con el precio más bajo (71,21 BRL) y queda en el puesto

Parte 7: Principales Hallazgos

Métrica	Valor Cuantitativo	Perspectiva Operativa
Escala del Dataset	99.441 pedidos de 96.096 clientes en 27 estados	Pedidos entre sep 2016 y oct 2018; el 99,6% se concentra entre ene 2017 y ago 2018. Solo el 3,4% de los pedidos son de clientes recurrentes
Crecimiento YoY de Pedidos	+135,07% (ene-ago 2017 vs 2018)	El volumen se multiplicó por 2,35 y en 2018 se estabiliza entre 6.167 y 7.269 pedidos al mes
Horario de Mayor Demanda	10:00-22:59 concentra el 81,5% de los pedidos; máximo a las 16:00	Demanda sostenida, sin un único pico; de 02:00 a 06:00 hay menos de 520 pedidos por hora
Concentración de Clientes	SP, RJ y MG reúnen el 66,5% de los clientes (SP solo, 41,9%)	14 estados aportan menos del 1% de los clientes cada uno
Disparidad Regional de Tiempo de Entrega	Brecha de 3,5x (RR: 28,98 días vs SP: 8,30 días)	Los 5 estados más lentos son del Norte y Nordeste; los 5 más rápidos, del Sureste, el Sur y el Distrito Federal
Preferencias de Pago	Tarjeta de crédito: 76,9% de los pedidos	El 66,9% de los pagos con tarjeta se hace en 2 o más cuotas
Categorías Líderes	Belleza y salud: 9,3% de los ingresos	Las 5 principales categorías suman casi el 40% y las 15 primeras, cerca del 76%.